

基于 LSTM-OCSVM 的无人机传感器数据异常检测

李 晨,王布宏,田继伟,郭戎潇

(空军工程大学 信息与导航学院,西安 710077)

E-mail: lichen2018@foxmail.com

摘要: 无人机是一种典型的依靠通信和控制系统实现自主飞行的信息物理系统,在安全性和可靠性方面引起了广泛的关注。本文考虑无人机传感器易受网络攻击问题,充分利用数据的时间相关性,提出了针对无人机传感器数据的异常检测模型。首先采用 LSTM 神经网络对传感器数据进行预测,再将预测值与实际值做差,并将差值输入 LSTM 分类器进行训练得到包含正样本的超平面,最后计算测试数据到超平面的距离函数值,根据其正负判定异常与否。并且,选择了合适的滑动窗口,在保证异常检测准确率的同时,缩短 LSTM 神经网络的训练时长。通过仿真实验,验证了该异常检测模型的可行性和有效性。

关键词: 无人机;异常检测;神经网络;长短期记忆网络;一类支持向量机

中图分类号: TP391

文献标识码: A

文章编号: 1000-1220(2021)04-0700-06

Anomaly Detection Method for UAV Sensor Data Based on LSTM-OCSVM

LI Chen, WANG Bu-hong, TIAN Ji-wei, GUO Rong-xiao

(Information and Navigation College, Air Force Engineering University, Xi'an 710077, China)

Abstract: Unmanned aerial vehicle (UAV) is a typical cyber physical system that relies on communication and control system to realize autonomous flight, and its security and reliability have attracted extensive attention. Considering the vulnerability of UAV sensors to data attacks, this paper made full use of the time correlation of data and proposed an anomaly detection model for UAV sensor data. Firstly, LSTM neural network was used for sensor data prediction, and then the difference between train and prediction was put into OCSVM for training to obtain the hyperplane containing positive samples. Finally, the distance function value of the test data to the hyperplane was calculated, and the anomaly value was determined according to the distance function value. In addition, a suitable sliding window is selected which can ensure the accuracy of anomaly detection and reduce the training time of LSTM neural network. The feasibility and effectiveness of the anomaly detection model are verified by simulation experiments and tests.

Key words: UAV; anomaly detection; neural network; long short-term memory network; one-class support vector machine

1 引言

无人机凭借其机动性好、价格低廉、方便快捷、无人驾驶等特点^[1],在军事领域和民用领域都发挥着越来越重要的作用。无人机在给我们的生活带来各种便利的同时,其面临的安全问题也逐渐暴露出来^[2,3]。目前无人机面临的攻击和威胁主要集中在:无线信号劫持与干扰、GPS (Global Positioning System, 全球定位系统)欺骗、传感器攻击、通信网络攻击,这些都可能造成无人机的飞行能力下降或轨迹异常,并造成信息泄露^[4,5]。

无人机系统的实时控制和通信能力使得其具有广阔的发展空间和前景,但同时也容易遭受可能的数据攻击。在无人机系统中,主控制器根据各种传感器采集到的数据,向动力系统下达相应的指令,以保障无人机的正常飞行和工作^[6]。因此,传感器所采集到的虚假数据很可能使无人机做出错误的决策,影响无人机的飞行安全。在现有的研究中,攻击者可以通过各种方式对传感器进行欺骗,如在传感器反馈链路中

截获并注入虚假数据,或使机载处理器过载,从而导致传感器与控制器之间的通信中断^[7]。另外,由于技术和成本的限制,一般机载传感器往往无法对正常和异常的信息进行检测和区分。传感器是无人机感知自身状态和外界变化的基础,一旦出现异常或者故障,可能会造成无人机不按指令正常飞行,继而导致事故发生,因此针对无人机飞行数据的异常检测是至关重要的^[8]。

异常检测方法主要可分为3大类,基于知识的异常检测方法、基于物理模型的异常检测方法和基于数据驱动的异常检测方法^[9]。前两种方法需要充分了解领域知识或系统结构才能达到较好的检测效果,然而无人机的各个子系统很难建立精确的物理模型,同时无人机实际飞行数据中异常样本较少,一般只能较好的检测已知的异常模式,因此检测适用性、抗干扰能力较差^[9,10]。基于数据驱动的异常检测方法可以细分为基于相似性的方法、基于统计的方法、基于分类的方法、基于预测的方法^[10]。文献[11]研究分析了无人机控制系统状态估计中数据攻击带来的安全威胁,提出了新息序列驱动的

无人机控制系统数据攻击的检测方法,该方法建立在对传感器十分了解的基础上,并且不能自适应检测数据中出现的新的异常模式.文献[12]提出了一种用于虚假数据注入攻击检测的神经网络自适应结构,该设计利用扩展卡尔曼滤波优化神经网络的权值,提高了神经网络的学习速度,然而该实验所设计的攻击较为简单,因而适用度不高.文献[13]提出一种用于无人机异常检测的长短期记忆(LSTM)递归神经网络方法,通过预测结果和预测不确定性的估计来实现异常检测,但其实验对象为单维数据变量,而且易受参数选取的影响不能有效检测.

无人机在飞行过程中产生的传感器数据是典型的时间序列,基于预测的异常检测方法可以根据历史信息提前计算出下一时刻的飞行状态.如果预测数据与实际传感器数据有较大偏差,则此刻无人机可能遭受攻击出现异常.LSTM神经网络对非线性和非平稳时间序列具有较强的逼近能力^[14],一般的统计方法需要人工分析预测误差来确定阈值,如:余弦相似度、欧氏距离,本文选用 OCSVM 具有更好的适应性,并能较好地处理只有单样本分类问题.基于历史无人机传感器数据,通过 LSTM 模型训练出预测样本,并将预测前后的差值序列作为样本送至 OCSVM 检测模型,训练出超平面分类器,根据距离函数值的正负,判断是否为异常点.实验结果表明该检测模型能有效判定针对无人机传感器的数据攻击,并具有较好的检测效果.

2 相关理论

2.1 长短期记忆网络(LSTM)

循环神经网络(Recurrent Neural Network, RNN)是一种用来处理时间序列数据的深度学习方法,广泛应用于语音识别、机器翻译、自然语言建模描述等诸多领域^[15].但在实际运用中,由于原始 RNN 存在梯度消失和梯度爆炸现象^[14],因而无法处理过长序列. Hochreiter & Schmidhuber 提出了 LSTM^[16],作为一种改进型的 RNN,通过 3 个门控状态控制信息传输,遗忘不重要信息,长期记忆需要的信息,有效解决了 RNN 存在的长依赖问题. LSTM 具有较强的长期记忆能力,更适合分析时间序列,在时间序列异常的检测中发挥着越来越大的作用.




图1 LSTM单元的结逻辑架构示意图

Fig.1 LSTM unit logical architecture diagram

普通 RNN 的隐含层节点结构简单,只有一个 Sigmoid 或 Tanh 激活函数,只是把上一次的状态作为本次的输入一起输出. LSTM 在状态的更新做了灵活地选择,遗忘门用于丢弃部

分存储信息,输入门用于控制新信息的比例完成状态的更新,输出门用于控制此时存储信息的输出部分.

如图1所示为 LSTM 单元的逻辑架构图,当 t 时刻的数据 x 输入 LSTM 时,便与 $t-1$ 时刻的长期状态 C_{t-1} 和输出 h_{t-1} 一起参与运算,得到 t 时刻 LSTM 的输出 h_t , h_t 便为所求 t 时刻的预测数据,则 LSTM 具体更新公式为:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (1)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3)$$

$$C_t = f_t \otimes C_{t-1} + i_t \otimes \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4)$$

$$h_t = o_t \otimes \tanh(C_t) \quad (5)$$

W_i, W_o, W_f 分别为输入门、输出门、遗忘门的权重系数, b_i, b_o, b_f 为偏置矢量, $\sigma(\cdot)$ 为 Sigmoid 激活函数, $\tanh(\cdot)$ 为双曲正切函数. 通过这样的门结构,使得 LSTM 神经网络具有保持长期依赖信息的能力,有效增加了记忆的长度,适用于长时间序列问题的处理.

2.2 一类支持向量机(OCSVM)

一类支持向量机(OCSVM)是 Schölkopf^[17]等提出的一种用于解决有限数据分类问题的无监督机器学习方法.该模型旨在把样本通过核函数^[18]映射到高维特征空间,在高维特征空间中构造线性判别函数来实现样本的分类,同时具有较好的泛化能力.

对于给定的不含标签的 k 个训练样本,其中有小部分属于孤立点, OCSVM 目标是确定正常样本的边界,即最优超平面,也就是要找到函数 $F(x)$,使得样本中大部分取值为 $+1$,而在孤立点上的取值为 -1 . 分类问题可以看做是,在映射的高维特征空间中寻找最优分类超平面,对应于 $F(x)$ 决定样本点所属的区域.

OCSVM 可以转化为寻求最小化目标函数:

$$\min_{w, \zeta_i, \rho} \frac{1}{2} \|w\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \zeta_i - \rho \quad (6)$$

$$s. t. \begin{cases} (w^T \phi(x_i)) > \rho - \zeta_i, i = 1, \dots, n \\ \zeta_i > 0 \end{cases}$$

其中: x_i 为样本数据, n 为训练集数量, ζ_i 为松弛因子, ν 为权衡参数, ϕ 为原始空间到特征空间映射, w 和 ρ 分别为特征空间中超平面的法向量和补偿.

引入拉格朗日乘子和径向基函数,可将约束条件下的目标优化问题转化为特征空间的对偶问题^[19]:

$$\min_{\alpha} \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j K(x_i, x_j) \quad (7)$$

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (8)$$

约束条件为:

$$\sum_i \alpha_i = 1, 0 \leq \alpha_i \leq \frac{1}{\nu n} \quad (9)$$

由上式可求出:

$$\rho = \sum_{i=1}^n \alpha_i K(x_i, x_j) \quad (10)$$

决策函数为:

$$F(x) = \text{sgn}((\sum_i \alpha_i K(x_i, x_j)) - \rho) \quad (11)$$

对于训练数据 x_i , $F(x_i)$ 表明它在高维空间位于超平面的正负方向,正的为正常样本,负的为异常样本.

3 模型构建

3.1 异常检测阈值

本文用时间序列 $X = \{X_1, X_2, \dots, X_n\}$ 表示提取后的无人机传感器数据, n 为序列长度. 对于每个时刻有:

$$X_k^T = (x_1, x_2, x_3), 1 \leq k \leq n \quad (12)$$

其中 X_k 是一个三维列向量, 代表了无人机某一时刻的位置信息.

本文旨在解决无人机传感器数据的异常判定问题, 为了解决此问题, 需要建立异常数据的检测阈值. 图 2 展示了异常检测模型建立的流程图.




图 2 异常检测模型框架

Fig. 2 Overall framework of anomaly detection model

模型在训练阶段, 将提取数据进一步归一化后得到序列数据 $S = \{S_1, S_2, \dots, S_n\}$, 然后将处理后的无人机飞行数据输入到 LSTM 神经网络进行预测, 则可以得到相对应预测序列 $P = \{P_1, P_2, \dots, P_n\}$, 再将预测前后的数据序列做差得到:

$$D_k = P_k - S_k, 1 \leq k \leq n \quad (13)$$

模型在测试阶段, 将测试数据 X_k 输入模型, 经过模型分类求解后, 如若差值对应的距离函数值 $F(D_k)$ 为正, 则 X_k 被判定为正常数据; 如若差值对应的距离函数值 $F(D_k)$ 为负, 则 X_k 被判定为异常数据.

3.2 数据预处理

由于接收的无人机传感器数据存在一定的数据缺失和数据噪声, 为了保证 LSTM 神经网络预测的准确性, 需要对数据进行预处理.

考虑到通信链路和收发设备的影响, 无人机传感器数据在生成、传输和采集过程中都有可能掺杂有噪声数据, 使数据在较小范围内产生随机偏差, 由于无人机机动性较强, 本文默认噪声影响相对较小不作处理.

而在传输的过程中, 由于链路的不可靠性, 信号可能会无法解析或者传输数据的校验字段出现损坏, 都将导致无人机传感器数据无法有效获取, 从而出现无人机传感器数据的缺

失. 故数据缺失较多的无人机传感器数据不能选取为训练样本, 否则会降低 LSTM 神经网络预测的准确性, 进而降低模型的检测概率.

若某一趟飞行数据仅缺少少量传感器数据或者不缺少传感器数据, 则将这一趟飞行数据选取为训练样本. 对缺失的少量无人机传感器数据, 本文采用插值法进行补齐, 具体方法为: 计算缺失值前后数据的斜率, 根据斜率补齐缺失的传感器数据.

无人机传感器数据包括了经度、纬度、高度、俯仰角、偏航角、滚转角等信息, 本文主要研究了无人机位置数据的异常检测, 因此提取经度、纬度、高度作为三维数据特征.

为了消除指标之间量纲的不良影响, 同时为了减短模型的训练时长、使训练过程尽快收敛, 进一步将序列元素在每个维度中做归一化处理, 这里选用最大最小标准化方法:

$$S_k = \frac{X_k - \min(X)}{\max(X) - \min(X)} \quad (14)$$

通常无人机执行任务时的飞行计划是已知的, 而且训练集中包含了无人机的各种飞行状态, 故可通过训练集采集的传感器数据确定最大最小值, 进一步对数据进行归一化处理.

3.3 基于 LSTM 神经网络的预测模型

无人机传感器数据是具有时间相关性的一系列数据, 它任一时刻的高度、纬度、经度、角速度和角加速度等信息都与历史时刻和未来时刻相关. 为了实现无人机传感器数据的预测, 本文从输入层、LSTM 层、全连接层和输出层的角度设计了一种基于 LSTM 神经网络的预测模型, 如图 3 所示.




图 3 LSTM 预测模型

Fig. 3 Prediction model of LSTM

输入层: 为了充分捕捉数据的时间相关性, 本层采用滑动窗口机制输入时间序列数据. 设滑动窗口的长度为 h , 且滑动步长为 1, 那么对于输入时间序列 $\{X_{k-h+1}, X_{k-h+2}, \dots, X_{k-1}, X_k\}$, 预测的便是下一时刻 X'_{k+1} 的值. 例如, 当 $h=5, k=8$ 时, 输入 $[4, 8]$ 时刻的时序数据 $\{X_4, X_5, X_6, X_7, X_8\}$, 那么此时预测 X_9 的数据, 其值为 X'_9 . 同时设置 LSTM 神经网络训练次数 epochs、训练批尺度 batch_size.

LSTM 层: 利用 LSTM 能捕获数据的时序性, 并能解决梯度消失问题, 将其自动学习无人机传感器数据的抽象特征, 设置隐藏层神经元个数分别为 40, 80, 20. 同时, 为了提高模

型的泛化能力,避免过拟合,设置 dropout 比例。

全连接层:全连接层将其输入特征重新拟合,通过权重矩阵提取以前全部数据的局部特征,能够将网络的输出值映射成目标输出值。为了较好提取并保留特征,设置全连接层的神经元个数为 10。

输出层:输出层通过线性激活函数输出预测结果。

3.4 利用 OCSVM 算法分类

为了解决无人机传感器数据攻击检测阈值的自适应问题,本文将传感器数据预测序列和实际序列做差,得到差值序列为 $D_k = P_k - S_k$;将差值序列 D_k 输入 OCSVM 程序求解,根据训练集可以求得 OCSVM 的超平面分布;根据测试集可以求得每个差值到超平面的矢量距离函数值。其中,距离函数的正负就是判定数据异常与否的依据。为了使样本在特征空间中线性可分,需要利用核函数将样本从原始空间映射到一个更高维的特征空间。本文采用高斯核函数,其表达式为:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (15)$$

其中, x_i 和 x_j 是输入 OCSVM 的任意两个样本, γ 是高斯核参数。

3.5 异常检测模型评价指标

为正确评估分析模型的检测效果,可将实验结果分为 4 类,如表 1 所示。本文采用检测率 (TNR)、召回率 (TPR) 和准确率 (ACC) 作为评价指标,检测率 TNR 是指被模型判定为异常样本的数目占实际异常样本数目的比例,召回率 TPR 是指被模型判定为正常样本的数目占实际正常样本数目的比例,准确率 ACC 是指被模型正确预测的样本数目占实际总样本数目的比例。上述 3 个指标的值越大, LSTM-OCSVM 异常检测模型的性能越佳。

表 1 样本分类结果

Table 1 Classification results of sample

真实情况	预测为正常	预测为异常
实际为正常	TP (true positive)	FN (false negative)
实际为异常	FP (false positive)	TN (true negative)

评价指标具体计算如下:

$$TNR = \frac{TN}{FP + TN} \quad (16)$$

$$TPR = \frac{TP}{TP + FN} \quad (17)$$

$$ACC = \frac{TN + TP}{TP + FN + FP + TN} \quad (18)$$

4 实验与分析

4.1 实验环境

本文实验采用 Tensorflow 深度学习框架,使用 Python 语言编程实现,实验运行环境为 JetBrains PyCharm Community Edition 和 MATLAB 2016a 软件,操作系统为 Windows 10 (64 位),内存为 8 GB,处理器为 Intel (R) Core (TM) i7-6500U 2.59GHz。

4.2 数据获取

本文选用的实验数据来自于 Zurich 大学机器人和感知小组^[20],通过无人机在城市街道上低空飞行采集,包含了

GPS 和惯性测量单元 (Inertial measurement unit, IMU) 传感器数据、地面街景图像数据。根据时间戳的特性,选取了等时间间隔的 80000 条无人机位置数据,其中前 60000 条数据作为训练样本,后 20000 条数据分为 40 组,每组实验 500 条数据进行测试。选取的无人机飞行数据包含了爬升、下降、变向等运动,具有一定的代表性,其中的一条测试轨迹如图 4 所示。针对无人机传感器的数据攻击主要有重放攻击、DOS 攻击、数据篡改攻击,本文假定攻击已经成功,攻击数据由模拟生成并加到测试数据段中,具体如下:

高度偏差 (数据篡改):前 150 条、后 150 条数据不作任何处理;对中间 200 条飞行数据的高度信息进行篡改,以 0.5 英尺为倍数,逐步改变高度信息。具体来说,第 151 条数据的高度信息增加 0.5 英尺,第 152 条数据的高度信息增加 1 英尺,依次类推直至第 350 条数据。

随机位置偏移 (数据篡改):前 150 条、后 150 条数据不作任何处理;中间 200 条飞行数据,在经纬度上加入均值为 0,标准差为 0.00001 的高斯白噪声。

航迹消失 (DOS 攻击):前 150 条、后 150 条数据不作任何处理;在 150 条数据 350 条数据之间发动 DOS 攻击,大量占用传输信道,造成控制端没有任何数据反馈。




图 4 无人机轨迹示意图

Fig. 4 UAV trajectory diagram

航迹替换 (重放攻击):前 150 条、后 150 条数据不作任何处理;中间 200 条飞行数据,攻击者发动重放攻击,将之前监测记录的第 126 条-第 150 条数据段连续发送了 8 次给控制端。

4.3 参数选取

在 LSTM 神经网络中,通过单变量控制法观察预测前后样本的均方误差值和运行时间,分别确定出训练次数 epochs




图 5 滑动窗口长度效果对比

Fig. 5 Comparison of sliding window length

= 40, 每组样本数 batch_size = 100, dropout 比率为 0.2, 优化器选择 Adam 时, LSTM 预测效果较好。特别地,对于滑动窗

口长度的选择,既要充分考虑无人机传感器数据的时间相关性,同时也要考虑运算时间.如若滑动窗口太小,则 LSTM 神经网络会失去大量的时间相关信息,使得预测效果不佳;如若滑动窗口太长,LSTM 神经网络会捕捉到大量的时间相关信息,但也会预测过拟合,大大降低预测的时效性.本文以预测前后样本的均方误差和 LSTM 神经网络完成一轮训练所需的时间作为衡量指标,对不同时间长度的滑动窗口作以对比,如图 5 所示.由于无人机飞行机动性较大,滑动窗口长度对应的预测效果好坏也有波动,综合考虑预测时效以及预测准确度,这里选择滑动窗口长度为 9.

在 OCSVM 检测模型中,需要调节响应参数(ν, γ)来达到理想的检测效果.本文采用通过大量实验观测并计算检测准确率,最终取权衡参数 $\nu=0.1$,高斯核参数 $\gamma=0.1$.

4.4 实验结果与分析

如图 6-图 9 所示为对应 4 种攻击的检测判定图.其中,图 6 描述的是注入高度偏差攻击后的检测判定图,横坐标取 500




图 6 高度偏差攻击检测图

Fig. 6 Detection of height deviation

个时刻,纵坐标取距离函数,阈值为 0.在该图中,对于异常样本,150 时刻 350 时刻对应的距离函数值共有 185 个 < 0 ,故检测率为 92.5%;对于正常样本,在其余 300 时刻对应的距离函数值共有 291 个 ≥ 0 ,故召回率为 97%;对于总样本,预测结果和实际样本一致的有 476 个,故准确率为 95.2%.




图 7 随机位置偏移检测图

Fig. 7 Detection of random offset

同理,如图 7-图 9 所示,随机位置偏差攻击的检测率为 87.5%,召回率为 82.6%,准确率为 84.6%;DOS 攻击的检测率为 99%,召回率为 97%,准确率为 97.8%;重放攻击的检测

率为 87.5%,召回率为 91.3%,准确率为 89.8%.




图 8 DOS 攻击检测图

Fig. 8 Detection of DOS attack

实验中,一共用 LSTM-OCSVM 异常检测模型测试了 40 段无人机飞行数据,取 40 次实验的均值作为异常检测的结果.表 2 列出了该模型的异常检测结果.从表 2 中可以看出,




图 9 重放攻击检测图

Fig. 9 Detection of replay attack

LSTM-OCSVM 模型的检测率均可达 86.2% 以上,召回率可达 83.0% 以上,准确率可达 84.6% 以上.另外,对于 DOS 攻击的检测效果最佳,这是因为航迹出现了消失,停留在发动攻

表 2 异常检测结果

Table 2 Results of anomaly detection

	检测率(%)	召回率(%)	准确率(%)
高度偏差	92.7	95.2	94.1
随机位置偏移	86.2	83.0	84.6
DOS 攻击	98.2	93.5	95.3
重放攻击	87.3	91.1	88.7

击前的时刻,并于攻击结束后发生位置跳变,因此也最容易被检测;对于随机偏差攻击的检测效果相对较差,这是因为本身数据采集就含有噪声,如若为了攻击的隐蔽性加入的攻击变量不大,此时确实较难检测.计算可得,针对上述 4 种攻击,平均检测率为 91.1%,平均召回率为 90.7%,平均准确率为 90.675%.

5 结束语

本文考虑了无人机传感器数据的时间相关性,提取了经度、纬度、高度作为特征数据,利用 LSTM 神经网络对位置数

据进行了预测,并将预测前后的差值序列输入 OCSVM 分类器训练,可以得到包含正常样本的超平面,根据测试样本差值计算到超平面的距离函数值进行检测.我们利用真实采集的无人机传感器数据并构造了含有攻击的测试数据,实验结果表明,LSTM 可用于检测针对无人机传感器数据的 DOS 攻击、重放攻击、高度偏差攻击、随机偏移攻击,且适用性较好.

然而,由于无人机具有动态变化性,随着飞行控制指令的改变,传感器数据可能会有较大波动,造成错误检测,同时对于攻击造成的微小状态变化不易检测.该模型针对随机位置偏移攻击和重放攻击检测率并不够高,下一步工作是继续改进检测模型提升对上述两种攻击的检测精度,并考虑研究攻击的实时检测.

References:

- [1] Pajares, Gonzalo. Overview and current status of remote sensing applications based on unmanned aerial vehicles (UAVs)[J]. *Photogrammetric Engineering & Remote Sensing*, 2015, 81(4): 281-330.
- [2] Sedjelmaci H, Senouci S M, Ansari N. A hierarchical detection and response system to enhance security against lethal cyber-attacks in UAV networks[J]. *IEEE Transactions on Systems Man & Cybernetics Systems*, 2018, 48(9): 1594-1606.
- [3] Krishna C G L, Murphy R R. A review on cybersecurity vulnerabilities for unmanned aerial vehicles[C]//*IEEE International Symposium on Safety, Security and Rescue Robotics (SSRR)*, IEEE, 2017.
- [4] Liu Wei, Feng Bing-wen, Weng Jian. Survey on research of mini-drones security[J]. *Chinese Journal of Network and Information Security*, 2016, 2(3): 39-45.
- [5] He Dao-jing, Du Xiao, Qiao Yin-rong, et al. A survey on cyber security of unmanned aerial vehicles[J]. *Chinese Journal of Computers*, 2019, 42(5): 1076-1094.
- [6] Youn W, Rhudy M B, Cho A, et al. Fuzzy adaptive attitude estimation for a fixed-wing UAV with a virtual SSA sensor during a GPS outage[J]. *IEEE Sensors Journal*, 2020, 20(3): 1456-1472.
- [7] Hu Y, Li H, Luan T H, et al. Detecting stealthy attacks on industrial control systems using a permutation entropy-based method[J]. *Future Generation Computer Systems*, 2020, 108(7): 1230-1240.
- [8] Egidio D, Massimiliano M, Immacolata N, et al. UAV sensor FDI in duplex attitude estimation architectures using a set-based approach[J]. *IEEE Transactions on Instrumentation & Measurement*, 2018, 67(10): 2465-2475.
- [9] Peng Yu, He Yong-fu, Wang Shao-jun, et al. Flight data anomaly detection: a survey[J]. *Journal of Instrumentation*, 2019, 40(3): 1-13.
- [10] Chen Ya-feng. Real-time anomaly detection system For unmanned aerial vehicle flight data[D]. Harbin: Harbin Institute of Technology, 2017.
- [11] Xiao Jia-ping, Jiang Jian-chun, She Chun-dong. Data attack detection for an unmanned aerial vehicle control system using innovation sequences[J]. *Journal of Control Theory and Applications*, 2017, 34(12): 1575-1582.
- [12] Abbaspour A, Yen K K, Noei S, et al. Detection of fault data injection attack on UAV using adaptive neural network[J]. *Procedia Computer Science*, 2016, 95: 193-200, doi:10.1016/j.procs.2016.09.312.
- [13] Wang B, Wang Z, Liu L, et al. Data-driven anomaly detection for UAV sensor data based on deep learning prediction model[C]//*Prognostics and System Health Management Conference (PHM-Paris)*, IEEE, 2019.
- [14] Shi Qing-yan, Yue Ju-cai, Han Ping, et al. Short-term flight trajectory prediction based on LSTM-ARIMA model[J]. *Journal of Signal Processing*, 2019, 35(12): 2000-2008.
- [15] Miao Y, Gawayyed M, Metze F. EESSEN: end-to-end speech recognition using deep RNN models and WFST-based decoding[C]//*IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU)*, 2015: 167-174.
- [16] Ji Xun-sheng, Wang Da-zhi, Li Xiao. Early prediction of elevator failures for unequal length time sequences[J]. *Journal of Chinese Computer Systems*, 2020, 41(4): 763-768.
- [17] Shang Wen-li, Yan Teng-fei, Zhao Jian-ming, et al. Method of autoencoder feature reduction and double model anomaly detection on industrial control network behavior[J]. *Journal of Chinese Computer Systems*, 2018, 39(7): 1405-1409.
- [18] Miao X, Liu Y, Zhao H, et al. Distributed online one-class support vector machine for anomaly detection over networks[J]. *IEEE Transactions on Cybernetics*, 2018, 49(4): 1475-1488.
- [19] Kang S, Kim D, Cho S. Approximate training of one-class support vector machines using expected margin[J]. *Computers & Industrial Engineering*, 2019, 130(4): 772-778.
- [20] Majdik A L, Till C, Scaramuzza D. The zurich urban micro aerial vehicle dataset[J]. *International Journal of Robotics Research*, 2017, 36(3): 1-5.

附中文参考文献:

- [4] 刘 炜, 冯丙文, 翁 健. 小型无人机安全研究综述[J]. *网络与信息安全学报*, 2016, 2(3): 39-45.
- [5] 何道敬, 杜 晓, 乔银荣, 等. 无人机信息安全研究综述[J]. *计算机学报*, 2019, 42(5): 1076-1094.
- [9] 彭 宇, 何永福, 王少军, 等. 飞行数据异常检测技术综述[J]. *仪器仪表学报*, 2019, 40(3): 1-13.
- [10] 陈亚锋. 无人机飞行数据实时异常检测系统研制[D]. 哈尔滨: 哈尔滨工业大学, 2017.
- [11] 肖佳平, 蒋建春, 余春东. 新息序列驱动的无人机控制系统数据攻击检测[J]. *控制理论与应用*, 2017, 34(12): 1575-1582.
- [14] 石庆研, 岳聚财, 韩 萍, 等. 基于 LSTM-ARIMA 模型的短期航班飞行轨迹预测[J]. *信号处理*, 2019, 35(12): 2000-2008.
- [16] 吉训生, 王大智, 李 晓. 面向不等长时间序列的电梯故障早期预测[J]. *小型微型计算机系统*, 2020, 41(4): 763-768.
- [17] 尚文利, 闫腾飞, 赵剑明, 等. 工控通信行为的自编码特征降维和双轮廓模型异常检测方法[J]. *小型微型计算机系统*, 2018, 39(7): 1405-1409.